



Presentado por: Joakin Mac Auliffe

¿QUÉ ES APACHE SPARK?

“Framework multilenguaje para la ingeniería de datos, data science y machine learning.”




Matei Zaharia

- Desarrollado en 2009 por Matei Zaharia en el AMPLab de la Universidad de California en Berkeley
- Spark se convirtió en código abierto en 2010 bajo una licencia BSD.
- En 2013 es donado a la fundación Apache Software Foundation.

MAP REDUCE

- Procesa en paralelo
- Escalable horizontalmente
- Tolerante a fallos




Sin embargo, Map Reduce depende de constantes operaciones de disco para persistir resultados intermedios y finales, provocando un costo enorme de escritura/lectura.

GESTIÓN DE DATOS EN SPARK

Spark utiliza RDDs (Resilient Distributed Datasets) y los almacena en la **memoria RAM**, aumentando su eficiencia enormemente.


Los RDD son una colección de elementos distribuidos.




PROCESO LÓGICO DE SPARK

En vez de seguir una secuencia lineal (Map, Shuffle, Reduce), Spark crea un **DAG (Grafo Dirigido Acíclico)**.

El DAG representa la ruta más eficiente, fusionando tareas y evitando mover información innecesaria. Además, es tolerante a fallas pues guarda todas las instrucciones y es capaz de reconstruir los datos.



ARQUITECTURA DE SPARK



La parte más costosa ocurre dentro de los executors, de esta manera haciendo uso distribuido de la memoria RAM de los nodos.

LIBRERÍAS DE SPARK

- SparkSQL: Utiliza **dataframes** para poder realizar consultas SQL.
- Spark Streaming: Permite procesar datos en tiempo real dividiendo el flujo continuo en pequeños trozos.



- MLlib: Biblioteca de **machine learning** de Spark. Incluye algoritmos listos para usar de clasificación, regresión, agrupación (clustering) y filtrado colaborativo.
- GraphX: Librería de análisis de grafos de Spark. Útil para realizar análisis de nodos y aristas mediante algoritmos como **PageRank**, **Connected Components** y **Triangle Counting**.